

今天的内容

- 期末复习
- 复习内容:
 - 搜索算法
 - 约束满足问题求解
 - 博弈树
 - 命题逻辑
 - 概率方法

智能体(Agent)有关概念


- 智能体(Agent)
 - 一个能感知和行动的实体；关键是如何实现一个智能体函数
- 智能体函数(Agent function)
 - 给定每个可能的感知序列，规定了智能体相应的行动
- 智能体程序(Agent program)
 - 结合机器的物理框架，程序实现了一个智能体函数
- 合理性(Rationality)
 - 一个属性，根据最大化的期望利益值来选择行动
 - 举例：只能采集到环境状态的部分信息的智能体不可能是非常合理的？
- 自主性(Autonomy)
 - 一个属性，智能体的行为是由自己的经验决定的，而不是仅由初始程序决定的

搜索问题里的概念

- 状态
 - 智能体所在的一个处境。两类状态：真实世界的，和抽象代表的（被智能体用于推测行动的）
- 搜索树
 - 一个树，根节点是开始状态，子节点代表可以通过行动达到的状态
- 搜索节点
 - 搜索树里的一个节点
- 目标状态
 - 智能体想要到达的状态
- 转移模型
 - 描述智能体给定一个状态后的选项（包括一组(行动，状态)对，即行动可以达到的状态）
- 分支因子
 - 搜索树中，智能体可选的行动数

搜索树

- 画出搜索树




树搜索 vs 图搜索

- 图搜索把扩展过的节点存下来，以后不会再扩展这些节点；而树搜索则有可能会重复扩展这些节点。


深度优先图搜索

- 返回路径




广度优先图搜索

- 返回路径



基于成本的统一图搜索

作业习题




状态节点扩展顺序？

返回路径？

A* 图搜索

作业习题




状态节点扩展顺序？

返回路径？

局部算法

- 爬山算法
 - 不断向值增加的方向移动（爬山），知道到达一个顶峰，周围邻居的值都比它的小。
- 优势
 - 不用维护一个搜索树，只需知道当前状态节点的值
- 不足
 - 返回的可能是局部最优解
- 改进方法
 - 随机重新开始
 - 随机水平移动

全局和局部最优解



随机开始点


- 找到全局最优

随机水平移动

- 跳出“shoulder”
- 无限循环在“flat local maxima”

最小最大值算法

- 假设MAX和MIN是优化选择它们的行动
- 提供的是节点的下界值





普遍化的最小最大值法 (minimax)

- 如果不是零和游戏，或有超过两个玩家？

- 普遍情况：

- 终局（叶结点）的值是一组值
- 中间节点的值也是一组值
- *每个玩家最大化自己的利益值元素*
- 能够动态产生协作和竞争等关系...




次优化策略

- 假设玩家MAX和玩家MIN在玩一个有限回合的零和博弈游戏。**MAX**通过最小最大算法计算的树根节点的值是**M**。假设每个玩家在每一轮都至少有2个可能的行动方向。而且，不同行动路线导致不同的终局节点值。
- 判断以下论断：
 - 假设玩家MIN在每一轮的行动是次优化的，并且玩家MAX知道它的对手行动是次优化的，那么存在一种策略使得玩家MAX能够在终局取得一个大于M的结果值？
 - 另一种假设，玩家MIN的行动选择在每一轮都是随机性的（且其概率是均匀分布的），并且玩家MAX知道这一点。对于玩家MAX来说，存在一种策略能够使得玩家MAX的期望终局结果值好于M？

Alpha-Beta 剪枝例子


α = 在当前路径上所有MAX节点中最大的值




节点产生的顺序与结果有关: 可能导致不同的可被剪掉的节点数量

Alpha-Beta 剪枝


- 假定修剪 **MIN** 节点的子节点
 - 假设正在计算节点 n 的 **最小-值**
 - n 节点的值在检查其子节点的过程中逐渐减小
 - 令 α 是从根到当前节点路径上的 **MAX** 分支节点所能达到的最大值
 - 如果 n 的当前值比 α 的小，那么路径上的 **MAX** 分支节点将会避开这条路径，所以我们可以剪掉(不去检查) n 的其他子节点
- 对 **MAX** 节点剪枝是对称的
 - 令 β 是从根到当前节点路径中的 **MIN** 分支节点所能达到的最小值





Alpha-Beta 剪枝测试



Alpha-Beta 剪枝测试2




搜索树中可能有机遇节点





井字游戏

最小最大值(Minimax)



投资游戏

期望最大值
(Expectimax)




大富翁游戏

期望最小最大值(Expectiminimax)

期望最小最大算法(ExpectiMiniMax)

作业习题




约束满足问题



- 计算机课程被安排在每周一，三，五。总共有5门课程，3名教师，每名教师在一个时间只能教一门课。如何安排每门课程的教师？
假设：
 - 课程包括：
 - 课程1 – 计算机编程简介， 时间 8: 00 – 9: 00AM
 - 课程2 – 人工智能导论， 时间 8: 30 - 9: 30AM
 - 课程3 – 软件工程， 时间 9: 00 – 10: 00 AM
 - 课程4 – 计算机视觉， 时间 9: 00 – 10: 00 AM
 - 课程5 – 机器学习， 时间 10: 30 – 11: 30AM
 - 教师包括：
 - 教师A，能够教课程1， 2， 5
 - 教师B，能够教课程3， 4， 5
 - 教师C，能够教课程1， 3， 4
- 描述为一个约束满足问题（假设一门课程是一个变量），指明每个变量的值域，及变量间的约束关系；约束关系可以是隐式表达形式。

回溯搜索


- 回溯搜索是基本的无启发式信息的算法，用来求解CSP问题
- 想法 1: 一次探索一个变量
 - 在每一步只需考虑给一个变量赋值
- 想法 2: 一边探索一边检查约束条件
 - 探索过程中检查当前的变量赋值是否满足约束条件
 - 也许需要花费一些计算来检查约束条件是否满足
 - “逐步增加的目标测试”
- 深度优先搜索结合这两点改进，就叫作 **回溯搜索**
- 能够解决 n -皇后问题，直至 $n = 25$



回溯搜索举例




树结构的 CSPs



- 定理: 如果约束图无环, 则其对应的约束满足问题的求解时间复杂度是 $O(n d^2)$
 - 比较一般的 CSPs, 最差时间复杂度是 $O(d^n)$

有用的概念: 弧的一致性 (连贯性; Consistency)

- 一个弧 $X \rightarrow Y$ 是 **一致的** 当且仅当 对于 X 中的 **每一个** x , Y 中存在 **某个** y 值 不违背任何一个约束条件




从弧的尾部删除

- 前向检查: 强制检查剩余未赋值变量指向新赋值变量的弧的一致性

树结构的 CSPs


- 树结构的CSPs的求解算法：
 - 排序: 选一个根节点, 把变量线性排序, 使得父节点排在子节点之前



- 从后向前删除: For $i = n : 2$, 应用 删除不一致的值(父节点 (X_i, X_i))
- 从前向后赋值: For $i = 1 : n$, 赋值 X_i 和父节点 $\text{Parent}(X_i)$ 相一致的值

树结构的 CSPs


- 声明 1: 在从后向前的一致性检查后, 所有根到叶的弧都是一致性的
- 证明: 每个 $X \rightarrow Y$ 如果是一致性的, 那么 Y 的值域以后不会被减小 (因为 Y 的子节点在 Y 之前先被处理过)



- 声明 2: 如果从根到叶的弧都是一致性的, 那么从前向后的赋值过程将不会有回溯
- 证明: 归纳法
- 为什么这个算法不适用于约束图中有环的情况?

逻辑

- 语法: 定义句子
- 语义:
 - *可能的世界*有哪些?
 - 这些句子在哪些世界里为 **真**? (句子真实性的**定义**)




语法空间



语义空间

推理的内容: 蕴涵(entailment)

- **蕴涵**: $\alpha \models \beta$ (“ α 牵涉(entails) β ” or “ β 遵循于(follows from) α ”)
当且仅当在 α 为真的每个世界里, β 也是真
 - 换句话说, α -的世界 (为真的那些世界) 是 β -的世界的一个子集
[$\text{models}(\alpha) \subseteq \text{models}(\beta)$]
- 例如, $\alpha_2 \models \alpha_1$
- (比如 α_2 是 $\neg Q \wedge R \wedge S \wedge W$
 α_1 是 $\neg Q$)



命题逻辑：语法

- 给定：一组 命题字符 $\{X_1, X_2, \dots, X_n, P, Q, R, \text{North}, \dots\}$ （可为真或假）
 - (True 和 False 也是，真值固定)
- X_i 是一个句子（原子句）
- 复杂句
 - 如果 α 是句子，那么 $\neg\alpha$ 是一个句子（否定）
 - 如果 α 和 β 是句子，那么 $\alpha \wedge \beta$ 是一个句子（结合）
 - 如果 α 和 β 是句子，那么 $\alpha \vee \beta$ 是一个句子（分离）
 - 如果 α 和 β 是句子，那么 $\alpha \Rightarrow \beta$ 是一个句子（暗含,或条件的if ...then）
 - 如果 α 和 β 是句子，那么 $\alpha \Leftrightarrow \beta$ 是一个句子（双向条件的 if and only if ）
 - 逻辑连接符，和（）的组合
- 文字(literal): 原子语句和否定的原子语句
- 没有其他样式的句子!

命题逻辑: 语义

- 给定一个模型（**model**），决定一个句子的真值
- 真值表

P	Q	$\neg P$	$P \wedge Q$	$P \vee Q$	$P \Rightarrow Q$	$P \Leftrightarrow Q$
<i>false</i>	<i>false</i>	<i>true</i>	<i>false</i>	<i>false</i>	<i>true</i>	<i>true</i>
<i>false</i>	<i>true</i>	<i>true</i>	<i>false</i>	<i>true</i>	<i>true</i>	<i>false</i>
<i>true</i>	<i>false</i>	<i>false</i>	<i>false</i>	<i>true</i>	<i>false</i>	<i>false</i>
<i>true</i>	<i>true</i>	<i>false</i>	<i>true</i>	<i>true</i>	<i>true</i>	<i>true</i>

逻辑上的一致性

$$(\alpha \wedge \beta) \equiv (\beta \wedge \alpha) \quad \text{commutativity of } \wedge$$

$$(\alpha \vee \beta) \equiv (\beta \vee \alpha) \quad \text{commutativity of } \vee$$

$$((\alpha \wedge \beta) \wedge \gamma) \equiv (\alpha \wedge (\beta \wedge \gamma)) \quad \text{associativity of } \wedge$$

$$((\alpha \vee \beta) \vee \gamma) \equiv (\alpha \vee (\beta \vee \gamma)) \quad \text{associativity of } \vee$$

$$\neg(\neg\alpha) \equiv \alpha \quad \text{double-negation elimination}$$

$$(\alpha \Rightarrow \beta) \equiv (\neg\beta \Rightarrow \neg\alpha) \quad \text{contraposition}$$

$$(\alpha \Rightarrow \beta) \equiv (\neg\alpha \vee \beta) \quad \text{implication elimination}$$

$$(\alpha \Leftrightarrow \beta) \equiv ((\alpha \Rightarrow \beta) \wedge (\beta \Rightarrow \alpha)) \quad \text{biconditional elimination}$$

$$\neg(\alpha \wedge \beta) \equiv (\neg\alpha \vee \neg\beta) \quad \text{De Morgan}$$

$$\neg(\alpha \vee \beta) \equiv (\neg\alpha \wedge \neg\beta) \quad \text{De Morgan}$$

$$(\alpha \wedge (\beta \vee \gamma)) \equiv ((\alpha \wedge \beta) \vee (\alpha \wedge \gamma)) \quad \text{distributivity of } \wedge \text{ over } \vee$$

$$(\alpha \vee (\beta \wedge \gamma)) \equiv ((\alpha \vee \beta) \wedge (\alpha \vee \gamma)) \quad \text{distributivity of } \vee \text{ over } \wedge$$

SAT问题

- 布尔满足问题
 - 例如，一个命题逻辑句子的可满足性
- $(A \wedge B) \vee (C \wedge D)$
 - 有多少可能的模型使该句为真？

可满足性和导出(蕴涵)

- 一个语句是 **可满足的**，如果它至少在一个世界里为真 (参见 CSPs!)
- 假设我们有一个超高效的 SAT solver; 我们如何能用它来测试蕴涵关系?
 - 假定 $\alpha \models \beta$
 - 那么 $\alpha \Rightarrow \beta$ 为真 在所有世界 (演绎公理)
 - 因此 $\neg(\alpha \Rightarrow \beta)$ 为假 在所有世界
 - 因此 $\alpha \wedge \neg\beta$ 为假 在所有世界, i.e., 不可满足的(unsatisfiable)
- 所以, 把否定的结论添加到 所知道的语句里, 测试其不可满足性 (un)satisfiability; 也叫 归谬法(reductio ad absurdum)
- 高效的 SAT solvers 需要 合取范式(**conjunctive normal form**)

合取范式(CNF)

替换双向条件，用两个暗示条件

替换 $\alpha \Rightarrow \beta$ 用 $\neg\alpha \vee \beta$

分配 \vee 到 \wedge



- 每个句子都能表达成一个子句
- 每个子句都是文字(正的或否定的符号)的析取
- 到 CNF 的标准变换:
 - $At_{1,1_0} \Rightarrow (Wall_{0,1} \Leftrightarrow Blocked_W_0)$
 - $At_{1,1_0} \Rightarrow ((Wall_{0,1} \Rightarrow Blocked_W_0) \wedge (Blocked_W_0 \Rightarrow Wall_{0,1}))$
 - $\neg At_{1,1_0} \vee ((\neg Wall_{0,1} \vee Blocked_W_0) \wedge (\neg Blocked_W_0 \vee Wall_{0,1}))$
 - $(\neg At_{1,1_0} \vee \neg Wall_{0,1} \vee Blocked_W_0) \wedge (\neg At_{1,1_0} \vee \neg Blocked_W_0 \vee Wall_{0,1})$

概率(Probability)

- 概率是对 复杂，不确定情况某种程度上的总结代表
 - 懒惰性(**laziness**): 太多的意外情况难以罗列, 等
 - 无知性(**ignorance**): 对某些情况缺乏了解和知识, 等
- 主观的(**Subjective**) or 贝叶斯(**Bayesian**) 概率:
 - 命题相关概率, 根据自己的知识
 - 例如, $P(\text{CatchPlane} \mid A_{120}, \text{sunny}) = 0.92$
- 命题有关概率随新知识观察的变化:
 - 例如, $P(\text{CatchPlane} \mid A_{120}, \text{sunny}, \text{NoDelaysOnBridge}) = 0.96$



概率的基本法则

- 开始于一组可能世界的集合 Ω
 - 例如, 一个骰子的6个可能结果, $\{1, 2, 3, 4, 5, 6\}$
- **概率模型(probability model)** 赋予一个数 $P(\omega)$ 给每一个世界 ω
 - $P(1) = P(2) = P(3) = P(4) = P(5) = P(6) = 1/6$.
- 这些数必须满足
 - $0 \leq P(\omega) \leq 1$
 - $\sum_{\omega \in \Omega} P(\omega) = 1$




基本法则（继续）

- 一个 **事件(event)** 是 Ω 的一个子集
 - “投数 < 4 ” 是集合 $\{1,2,3\}$
 - “投数是奇数”， $\{1,3,5\}$
- 一个事件的概率是在对应世界概率数值之和
 - $P(A) = \sum_{\omega \in A} P(\omega)$
 - $P(\text{投数} < 4) = P(1) + P(2) + P(3) = 1/2$



随机变量(Random Variables)

- 一个随机变量描述了世界中我们可能不确定的某个方面（正式的讲，是 ω 上的一个决定性的函数）
 - R = 天是否将会下雨？
 - Odd = 骰子的投数是否将会是一个奇数？
 - T = 天气是热还是冷？
 - D = 花费多长时间能够到达机场？
- 大写字母开头
- 随机变量也有值域
 - Odd in $\{true, false\}$ e.g. $Odd(1)=true$, $Odd(6) = false$
 - 通常把事件 $Odd=true$ 写成 odd , $Odd=false$ 写成 $\neg odd$
 - T in $\{hot, cold\}$
 - D in $[0, \infty)$



边缘分布(Marginal Distributions)

- 边缘分布是消除掉某些变量后的子表
- 边缘化 (加和): 通过求和来合并行

$P(T, W)$

T	W	P
hot	sun	0.4
hot	rain	0.1
cold	sun	0.2
cold	rain	0.3




$P(T)$

T	P
hot	0.5
cold	0.5

$P(W)$

W	P
sun	0.6
rain	0.4




$$P(X_1 = x_1) = \sum_{x_2} P(X_1 = x_1, X_2 = x_2)$$

条件概率(Conditional Probabilities)

- 联合概率和条件概率间的简单关系
 - 一个条件概率的定义

$$P(a|b) = \frac{P(a,b)}{P(b)}$$



$P(T, W)$

T	W	P
hot	sun	0.4
hot	rain	0.1
cold	sun	0.2
cold	rain	0.3

$$P(W = s|T = c) = \frac{P(W = s, T = c)}{P(T = c)} = 0.4$$

$$\begin{aligned} &= P(W = s, T = c) + P(W = r, T = c) \\ &= 0.2 + 0.3 = 0.5 \end{aligned}$$

条件分布(Conditional Distributions)

- 某些变量当其他变量的值固定的时候，的概率分布

条件分布

$P(W T)$	$P(W T = hot)$	
	W	P
	sun	0.8
	rain	0.2
	$P(W T = cold)$	
	W	P
	sun	0.4
	rain	0.6


联合分布

$P(T, W)$		
T	W	P
hot	sun	0.4
hot	rain	0.1
cold	sun	0.2
cold	rain	0.3

乘法规则(The Product Rule)

- 已有条件分布，想要计算联合分布

$$P(y)P(x|y) = P(x, y) \quad \longleftrightarrow \quad P(x|y) = \frac{P(x, y)}{P(y)}$$



乘法规则

$$P(y)P(x|y) = P(x, y)$$


- 举例:

$P(W)$

R	P
sun	0.8
rain	0.2

$P(D|W)$

D	W	P
wet	sun	0.1
dry	sun	0.9
wet	rain	0.7
dry	rain	0.3



$P(D, W)$

D	W	P
wet	sun	0.08
dry	sun	0.72
wet	rain	0.14
dry	rain	0.06

链式法则(The Chain Rule)

- 更普遍化的, 任何联合分布可以写成条件分布的增量相乘

$$P(x_1, x_2, x_3) = P(x_1)P(x_2|x_1)P(x_3|x_1, x_2)$$

$$P(x_1, x_2, \dots x_n) = \prod_i P(x_i|x_1 \dots x_{i-1})$$

贝叶斯法则(Bayes' Rule)

- 两种方法因式分解一由两个变量组成的联合分布:

$$P(x, y) = P(x|y)P(y) = P(y|x)P(x)$$

那是我的法则!

- 相除后, 我们得到:


$$P(x|y) = \frac{P(y|x)}{P(y)}P(x)$$

- 为什么这个有用?
 - 让我们计算一个条件概率, 从它的相反的形式
 - 通常一个条件概率很难计算, 但是相对应的另一个却很简单
 - 许多人工智能系统的基础
- 最重要的人工智能公式之一!



概率模型(Probabilistic Models)

- 模型描述的是世界（或某一部分）是如何工作的
- 模型总是一种简化
 - 可能忽略了某些变量和之间的交互关系
 - “所有模型都是错的;但某些是有用的.”
– George E. P. Box
- 概率模型能用来做什么?
 - 我们(或我们的人工智能体) 需要对未知变量进行推理，当给定一些证据后
 - 例如: 解释 (诊断推理)
 - 例如: 预测 (因果推理)
 - 例如: 基于期望利益值的决策
- 如何建立模型，并避免 d^n 的复杂性?



条件独立性（条件无关） Conditional Independence

- 无条件的 (绝对的) 独立性非常稀少 (为什么?)
- 条件独立性是我们对于不确定环境的最基本和强健的知识蕴藏形式
- X 是条件独立于 (conditionally independent) Y, 给定 Z

当且仅当:

$$\forall x, y, z \quad P(x | y, z) = P(x | z)$$

或, 等价地, 当且仅当

$$\forall x, y, z \quad P(x, y | z) = P(x | z) P(y | z)$$

贝叶斯网络: 宏观介绍


- 完全的联合分布表可以回答每一个问题，但是：

- 表的大小是变量数的指数级
- 需要大量的例子来学习相应的概率
- 用列举法 (加和消掉隐藏变量) 进行推理太慢



- 贝叶斯网络(Bayesian networks):

- 表达了一个由变量组成的领域里所有的条件独立性关系
- 联合分布因式分解为小规模条件概率分布的乘积
- 分布表达的量级从指数减少为线性
- 从较少的例子快速学习出模型
- 快速推理 (在某些重要实例里可以达到线性时间复杂度)
- “*Microsoft’s competitive advantage lies in its expertise in Bayesian networks*”
-- Bill Gates, quoted in LA Times, 1996




贝叶斯网络语法



- 一个节点对应一个变量 X_i
- 一个有向, 无环图
- 一个条件概率分布, 对每个节点 给定图中它的 **父节点**
 - **CPT**: 条件概率分布表:
 - 每一行是子节点的一个分布, 在给
定父节点的一个配置以后
- 一个近似的“因果”过程的描述

P(Ghost)			
(1,1)	(1,2)	(1,3)	...
0.11	0.11	0.11	...

Ghost	P(Color _{1,1} Ghost)			
	g	y	o	r
(1,1)	0.01	0.1	0.3	0.59
(1,2)	0.1	0.3	0.5	0.1
(1,3)	0.3	0.5	0.19	0.01
...				



贝叶斯网络 = 拓扑结构(图形) + 局部条件概率



贝叶斯网络的全局语法

- 贝叶斯网络整体表达了（编码）联合分布，作为每一个变量上条件分布的乘积：

$$P(X_1, \dots, X_n) = \prod_i P(X_i \mid \text{Parents}(X_i))$$

贝叶斯网络里的概率



- 为什么我们可以保证以下公式反映的是正确的联合分布

$$P(X_1, \dots, X_n) = \prod_i P(X_i | \text{Parents}(X_i))$$


- 连锁法 (对所有分布有效): $P(X_1, \dots, X_n) = \prod_i P(X_i | X_1, \dots, X_{i-1})$
- 假定 条件独立性: $P(X_i | X_1, \dots, X_{i-1}) = P(X_i | \text{Parents}(X_i))$
 - 当加入节点 X_i , 保证了其父节点“屏蔽”它与其他祖先节点的联系

→ 结果: $P(X_1, \dots, X_n) = \prod_i P(X_i | \text{Parents}(X_i))$

- 所以, 网络的拓扑结构暗示着肯定的条件独立性的成立


条件独立性的语义

- 每个变量在给定它的父变量节点情况下，则是条件独立于它的非后代变量



马尔科夫毯(Markov blanket)

- 一个变量的马尔可夫毯包括父节点, 子节点, 子节点的其他父节点
- 每个变量给定它的马尔科夫毯, 则是条件独立于所有其他变量



贝叶斯网络推理

- 精确推理
 - 列举法
 - 变量消除法
- 近似推理（采样法）
 - 先验采样(Prior Sampling)
 - 拒绝抽样(Rejection Sampling)
 - 似然性/可能性加权(Likelihood Weighting)
 - 吉布斯采样(Gibbs Sampling)

有关期末考试

- 时间：第18周的周一（12/30）
- 题型
 - 选择
 - 填空
 - 判断
 - 分析计算
 - 简答
- 主要内容
 - 智能体相关概念
 - 搜索算法
 - 博弈树
 - 约束满足问题
 - 命题逻辑
 - 概率