

通知

■期末考试为闭卷

时间定在12月23日星期三下午的第1，2节课（即2：40PM开始）

地点在 3-101


■作业答案和考试范围已在课程网页贴出

今天的内容

- 课程设计展示（有准备的同学做）
- 贝叶斯网络(Bayes nets)
 - 近似推理

人工智能导论

贝叶斯网络：近似推理 APPROXIMATE INFERENCE



采样 (Sampling)

采样很像重复的模拟

■ 基本思想


■ 抽取 N 样本，形成一个采样分布 S

■ 计算一个近似后验概率

■ 证明可以收敛到真实的概率 P

■ 为什么采样？

- 通常很快得到一个好的近似解
- 算法简单而且通用 (很容易应用在不同的概率模型上)
- 算法只需很少的存储空间 ($O(n)$)
- 可以应用于大的模型上；对比准确算法（比如变量消除法）



举例

- 假设你有两个大富翁游戏的智能体程序 **A** 和 **B**
- A 获胜的概率是多少?
 - 方法 1:
 - 让 **s** 是一序列的骰子数，机会和公益金牌
 - 给定 **s**, 结果 **V(s)** 可能是 1（赢）, 0（输）
 - **A** 赢的概率是 $\sum_s P(s) V(s)$
 - 问题: 无限多这样的序列 **s**!
 - 方法 2:
 - 采样 **N** (也许 100) 组序列从概率分布 **P(s)**, 即玩 **N** 次游戏
 - **A** 获胜的概率大概是 $(1/N) \sum_i V(s_i)$ 即在采样里获胜的比例

从一个离散分布中采样

■ 举例

■ 步骤 1: 获取一个采样 u 从均匀分布 $[0, 1)$

■ 例如 `random()`

■ 步骤 2: 把这个采样值 u 转化成一个给定分布的输出结果。（通过关联每个输出结果 x 和一个 $P(x)$ -大小的在 $[0,1)$ 上的一个子区间）

C	P(C)
red	0.6
green	0.1
blue	0.3

$0.0 \leq u < 0.6, \rightarrow C=\text{red}$

$0.6 \leq u < 0.7, \rightarrow C=\text{green}$

$0.7 \leq u < 1.0, \rightarrow C=\text{blue}$


- 如果 `random()` 返回 $u = 0.83$, 那么采样为 $C = \text{blue}$
- 再例如, 在8次采样以后有:



贝叶斯网络里的采样

- 先验采样 (Prior Sampling)
- 拒绝抽样 (Rejection Sampling)
- 似然性/可能性加权 (Likelihood Weighting)
- 吉布斯采样 (Gibbs Sampling)

先验采样(Prior Sampling)



先验采样

$$P(C)$$

c	0.5
$\neg c$	0.5

$$P(S|C)$$


c	s	0.1
	$\neg s$	0.9
$\neg c$	s	0.5
	$\neg s$	0.5

$$P(R|C)$$

c	r	0.8
	$\neg r$	0.2
$\neg c$	r	0.2
	$\neg r$	0.8

$$P(W|S, R)$$

s	r	w	0.99
		$\neg w$	0.01
	$\neg r$	w	0.90
		$\neg w$	0.10
$\neg s$	r	w	0.90
		$\neg w$	0.10
	$\neg r$	w	0.01
		$\neg w$	0.99



样本:

c, $\neg s$, r, w(这个例子里)

$\neg c$, s, $\neg r$, w


...

先验采样

For $i=1, 2, \dots, n$ (按拓扑顺序)

- 采样 x_i 从 $P(x_i | \text{parents}(x_i))$

Return (x_1, x_2, \dots, x_n)



先验采样

- 这个过程产生这样的样本的概率是:
-

$$S_{PS}(x_1 \dots x_n) = \prod_{i=1}^n P(x_i | \text{Parents}(X_i)) = P(x_1 \dots x_n)$$

...即 是贝叶斯网络的联合概率

- 让 一个事件的样本数为 $N_{PS}(x_1 \dots x_n)$

- 那么
$$\begin{aligned} \lim_{N \rightarrow \infty} \hat{P}(x_1, \dots, x_n) &= \lim_{N \rightarrow \infty} N_{PS}(x_1, \dots, x_n) / N \\ &= S_{PS}(x_1, \dots, x_n) \\ &= P(x_1 \dots x_n) \end{aligned}$$

- 即, 这个采样过程是 一致的/连续的 (**consistent**)

例如

我们从这个贝叶斯网络里获得一系列的样本：


$C, \neg S, r, W$

C, S, r, W

$\neg C, S, r, W$

$C, \neg S, r, W$


$\neg C, \neg S, \neg r, W$



如果我们想知道： $P(W)$


- 我们可以数出 $\langle w:4, \neg w:1 \rangle$
- 正规化后得到 $P(W) = \langle w:0.8, \neg w:0.2 \rangle$
- 样本越多，越接近真实的分布
- 还可以估计其他的概率量
- 比如，想查询概率 $P(C | r, w)$ ，使用 $P(C | r, w) = \alpha P(C, r, w)$

拒绝采样(Rejection Sampling)



拒绝采样

- 为了计算条件概率，对先验采样进行简单修改
- 假如我们想计算 $P(C | r, w)$
- 计算采样中 C 的结果，但是忽略（拒绝）那些不含有 $R=\text{true}$, $W=\text{true}$ 的样本
 - 这就叫做拒绝采样
 - 对于条件概率的估计，也是满足一致性的（即， N 趋于无限大时，等于理论真值）



$C, \neg S, r, w$

~~$C, S, \neg r$~~

~~$\neg C, S, r, \neg w$~~

~~$C, \neg S, \neg r$~~

$\neg C, \neg S, r, w$


拒绝采样 Rejection Sampling

输入: 观察值 e_1, \dots, e_k


For $i=1, 2, \dots, n$

- 采样 X_i 从 $P(X_i | \text{parents}(X_i))$
- 如果 x_i 和观察值不一致
 - 拒绝这个样本: **Return**, 则在这个循环里没有样本产生

Return (x_1, x_2, \dots, x_n)




似然性加权（采样） Likelihood Weighting




似然性加权（采样）

拒绝采样法的问题:

- 有可能拒绝许多样本，尤其当观察变量很多时
- 采样时没有利用已被观察变量的值
- 比如考虑 $P(\text{Shape}|\text{Color}=\text{blue})$




~~pyramid, green~~
~~pyramid, red~~
sphere, blue
~~cube, red~~
~~sphere, green~~




■ 想法: 固定观察变量的值，对其他变量值进行采样

- 问题: 样本分布与理论分布不一致!
- 解决办法: **权重** 每个样本，通过使用观察变量给定父变量的概率



pyramid, blue
pyramid, blue
sphere, blue
cube, blue
sphere, blue



似然性加权（采样）

w 初始化为1.0;
拓扑排序: C, S, R, W
S, W 值固定为真

$$P(C)$$


c	0.5
$\neg c$	0.5

$$P(S|C)$$

c	s	0.1
	$\neg s$	0.9
$\neg c$	s	0.5
	$\neg s$	0.5

$$P(R|C)$$

c	r	0.8
	$\neg r$	0.2
$\neg c$	r	0.2
	$\neg r$	0.8


$$P(W|S, R)$$

s	r	w	0.99
		$\neg w$	0.01
	$\neg r$	w	0.90
		$\neg w$	0.10
$\neg s$	r	w	0.90
		$\neg w$	0.10
	$\neg r$	w	0.01
		$\neg w$	0.99

样本事件:

c, s, r, w


...

样本事件的权值:

$$w = 1.0 \times 0.1 \times 0.99$$

似然性加权采样

- 输入: 观察值 e_1, \dots, e_k
- $w = 1.0$
- for $i=1, 2, \dots, n$
 - 如果 x_i 是已观察的变量 (evidence variables)
 - x_i = 观察到的 value _{i} for X_i
 - 让 $w = w * P(x_i \mid \text{Parents}(X_i))$
 - 否则
 - 抽样 x_i 从 $P(X_i \mid \text{Parents}(X_i))$
- return $(x_1, x_2, \dots, x_n), w$




似然性加权采样

- 采样分布为（ \mathbf{z} 为非观察变量的采样值 \mathbf{e} 为固定的观察值）

$$S_{WS}(\mathbf{z}, \mathbf{e}) = \prod_{i=1}^l P(z_i | \text{Parents}(Z_i))$$

- 现在, 每个样本都有权重

$$w(\mathbf{z}, \mathbf{e}) = \prod_{i=1}^m P(e_i | \text{Parents}(E_i))$$



- 合起来, 加权的样本分布是具有一致性的, 即:

$$\begin{aligned} S_{WS}(\mathbf{z}, \mathbf{e}) \cdot w(\mathbf{z}, \mathbf{e}) &= \prod_{i=1}^l P(z_i | \text{Parents}(z_i)) \prod_{i=1}^m P(e_i | \text{Parents}(e_i)) \\ &= P(\mathbf{z}, \mathbf{e}) \end{aligned}$$

似然性加权


■ 优点:

- 可利用所有样本（加权的）
- **下游** 变量的采样值会被 **上游** 已观察变量的值所影响

■ 也有弱点:

- **上游** 变量的采样值 不受 **下游** 观察变量值的影响
- 假设观察到的值在 k 个叶节点上, 那么样本的权重可能为 $O(2^{-k})$
- 随着观察变量的增多, 而且如果这些变量出现在拓扑顺序的后面, 那么许多样本的权值会很小, 只有极少的幸运样本将有相对很大的权值, 从而主导估计概率的结果
- 我们希望的是, 每个变量都可以“看见” **所有** 已观察到的值!

吉布斯采样(Gibbs Sampling)



马尔科夫蒙特卡洛 (Markov Chain Monte Carlo)

- MCMC (Markov chain Monte Carlo) 是随机算法家族一员，用来估计某个感兴趣的数值在一个很大的状态空间里
 - Markov chain = 一序列随机选择的状态 (“随机漫步 random walk”), 其中每个状态的选择是基于它前一个状态
 - Monte Carlo = 摩纳哥的旅游城市，有一个著名的赌场



马尔科夫蒙特卡洛理论


Markov Chain Monte Carlo

- MCMC 属于随机算法家族，用于在一个很大的状态空间里，近似估计某些感兴趣的量
 - 马尔科夫链 = 一序列随机选择的状态 (“随机漫步random walk”), 每个状态的选择是条件取决于前一个状态
 - 蒙特卡洛理论 Monte Carlo = 一种算法 (通常基于随机采样), 存在产生一个不正确解答的可能性 (概率)
- MCMC = 随机漫步一会，平均化你所观察到的情况

吉布斯采样 (Gibbs sampling)

- 属于 MCMC 家族一类
 - 状态是对所有变量的完整的赋值
 - (对比局部搜索里的 模拟退火算法, 属于同一算法家族!)
 - 观察 (证据) 变量的值固定, 改变其他变量的值
 - 当产生下一个状态时, 选出一个变量, 并对其采样一个值, 采样的分布是条件于所有其他变量
 - $X_i' \sim P(X_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$
 - 趋向于朝高概率发生的状态移动, 但也可能移动到一个低概率的状态
 - 在贝叶斯网络里, $P(X_i | x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) = P(X_i | \text{马可夫毯}(X_i))$
- 定理: 吉布斯采样是具有一致性的
 - 给定吉布斯分布概率是远离0和1, 并且变量选择是公平的

为什么这样做？



采样很快开始反应网络里所有的观察值（已观察节点的值对其他变量值的采样施加影响）

最终样本将从真实的后验概率分布上抽取！


如何进行采样？

■ 重复许多次：

■ 对一个非观察到的变量 X_i 进行采样，从概率分布：

■ $P(X_i \mid x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) = P(X_i \mid \text{马尔科夫毯}(X_i))$


■ $= \alpha P(X_i \mid u_1, \dots, u_m) \prod_j P(y_j \mid \text{parents}(Y_j))$



吉布斯采样举例: $P(S | r)$


Step 1: 固定观察值

- $R = \text{true}$




Step 2: 初始化其他变量

- 随机地



Step 3: 重复以下

- 选择一个非证据变量 X
- 重采样 X 从 $P(X | \text{马可夫毯}(X))$



采样 $S \sim P(S | c, r, \neg w)$

采样 $C \sim P(C | s, r)$


采样 $W \sim P(W | s, r)$

为什么这种方法有效?


- 假定运行这种方法很长一段时间, 并预测在时刻 t 到达任何一个状态的概率为: $\pi_t(x_1, \dots, x_n)$ or $\pi_t(\underline{x})$
- 对每个吉布斯采样步骤 (挑一个变量, 重采样它的值) 当它应用到一个状态 \underline{x} 时, 有一个概率 $q(\underline{x}' | \underline{x})$ 移动到下个状态 \underline{x}'
- 所以 $\pi_{t+1}(\underline{x}') = \sum_{\underline{x}} q(\underline{x}' | \underline{x}) \pi_t(\underline{x})$ 或, 用矩阵或向量形式表示:
$$\pi_{t+1} = Q\pi_t$$
- 当这一动态过程处于平衡, 即 $\pi_{t+1} = \pi_t$, 所以 $Q\pi_t = \pi_t$
- 这种情况下有一个唯一解, 即 $\pi_t = P(x_1, \dots, x_n | e_1, \dots, e_k)$
- 所以当时刻 t 足够大时, 下一个样本将会从真实的后验条件概率分布上被采集

贝叶斯网络采样技术小结

■ 先验采样 P





■ 拒绝采样法 $P(Q | e)$



■ 吉布斯采样 $P(Q | e)$

■ 似然加权采样法 $P(Q | e)$



期末考试说明

■ 闭卷，100分钟

■ 时间地点

■ 题型和范围

■ 选择，填空，计算，简答

■ 智能体和环境（相关概念）

■ 搜索算法（模型中的基本概念； A^* , 贪婪，基于成本的统一搜索等；树搜索和图搜索策略，局部搜索算法）

■ 约束满足问题（表达，求解，约束图）

■ 博弈问题（零和博弈，最小最大算法，期望最小最大算法，剪枝）

■ 命题逻辑（基本概念，基本规则，等效，合取范式）

■ 概率基本概念和计算，贝叶斯网络的基本概念